

Inteligencia Computacional

ENTREGABLE 1 — PROYECTO FINAL

Johan Sebastián Cáceres Rodríguez
20212005111

Joel Eduardo Reyes Barrios
20212005011

27 de abril de 2026



**UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS**
Acreditación Institucional de Alta Calidad

ÍNDICE

1. Introducción	4
2. Dataset y Selección de Rodamientos	4
2.1. Condición operacional seleccionada	4
2.2. Selección de rodamientos y clases	4
2.3. Distribución de clases	5
3. Análisis Exploratorio de Datos (EDA)	5
3.1. Señales disponibles	5
3.2. Impacto del dominio de representación	5
3.3. Estrategia de segmentación (Ventaneo)	6
3.4. Análisis de Correlación entre Canales de Señal	7
4. Metodología	9
4.1. Protocolo de validación LOBO	9
4.2. Arquitectura de la red	9
4.3. Configuración de entrenamiento	10
5. Evolución Experimental	10
5.1. Primera prueba: CNN 1D sobre señal cruda	10
5.2. Segunda prueba: incorporación de FFT logarítmica	10
5.3. Tercera prueba: regularización y correcciones de entrenamiento	10
5.4. Cuarta prueba: fusión de sensores sin FFT	11
5.5. Quinta prueba: reducción del solapamiento al 25 %	11
5.6. Sexta prueba: fusión de sensores con FFT logarítmica	11
5.7. Resumen de la evolución	11
6. Resultados Experimentales y Análisis	11
6.1. Modelos de referencia (Baseline)	12
6.2. Experimento 2: CNN 1D + FFT Log (50 % solapamiento)	13
6.3. Experimento 3: CNN 1D + FFT log + dropout + pesos de clase	14
6.4. Experimento 4: Fusión de sensores (corriente + vibración, sin FFT)	16

6.5. Experimento 5: CNN 1D + FFT Log (25 % solapamiento)	17
6.6. Experimento 6: Fusión de sensores (corriente + vibración) con FFT logarítmica	19
6.7. Discusión general de hallazgos	21
7. Conclusiones Preliminares	25

1 INTRODUCCIÓN

El diagnóstico de fallas en rodamientos constituye uno de los problemas más relevantes en el mantenimiento predictivo de maquinaria rotativa. La mayor parte de la literatura propone soluciones basadas en señales de vibración capturadas con acelerómetros dedicados; sin embargo, la instalación de este tipo de sensores implica costos de adquisición, calibración y cableado que limitan su adopción industrial generalizada. Una alternativa de menor costo consiste en extraer información diagnóstica directamente de las señales de corriente del motor eléctrico (*Motor Current Signature*, MCS), cuya medición es posible a través de los inversores de frecuencia ya instalados en planta.

Este primer entregable tiene como objetivo establecer la línea base experimental del proyecto. Para ello se realizó un análisis exploratorio del *Bearing Data Center* de la Universidad de Paderborn, se diseñó el pipeline de preprocesamiento y se evaluaron distintas configuraciones de una red neuronal convolucional unidimensional (1D-CNN) bajo un protocolo de validación estricto *Leave-One-Bearing-Out* (LOBO), que garantiza que el modelo sea evaluado sobre rodamientos físicos no vistos durante el entrenamiento.

2 DATASET Y SELECCIÓN DE RODAMIENTOS

Se utilizó el conjunto de datos del *Bearing Data Center* de la Universidad de Paderborn [lessmeier2016], ampliamente referenciado en la literatura de diagnóstico de fallas. El dataset incluye mediciones sincrónicas de corriente del motor y vibración del eje, adquiridas a una frecuencia de muestreo de 64 kHz bajo diferentes condiciones de carga y velocidad angular.

2.1 CONDICIÓN OPERACIONAL SELECCIONADA

Con el fin de reducir la variabilidad operacional y concentrar el análisis en un único escenario de trabajo, el experimento se restringió a la condición de **1500 RPM**. Esta decisión reduce la dimensionalidad del problema y facilita la interpretación de los resultados en esta primera fase.

2.2 SELECCIÓN DE RODAMIENTOS Y CLASES

Del conjunto completo se seleccionaron **15 rodamientos** organizados en tres clases, siguiendo el esquema de referencia del paper base:

- **Sano (H):** K001, K002, K003, K004, K005.
- **Daño Externo (OR):** KA01, KA03, KA05, KA06, KA07.
- **Daño Interno (IR):** KI01, KI03, KI05, KI07, KI08.

Los casos codificados como **KB** fueron excluidos del análisis debido a que representan fallas mixtas (daño simultáneo en aro interno y externo), lo cual dificulta la construcción de etiquetas claras para el entrenamiento supervisado e introduce ambigüedad en la frontera de decisión del clasificador.

2.3 DISTRIBUCIÓN DE CLASES

Con la selección descrita, el esquema de etiquetado queda reducido a **tres categorías: Sano, Daño Interno y Daño Externo**, con cinco rodamientos por clase. Esta distribución balanceada a nivel de instancias físicas es conveniente para la validación LOBO, aunque no garantiza balance perfecto a nivel de ventanas temporales debido a diferencias en la duración de cada experimento.

3

ANÁLISIS EXPLORATORIO DE DATOS (EDA)

La fase de exploración no se limitó a una descripción visual del dataset, sino que sirvió como etapa de **toma de decisiones metodológicas**. A través de ella se identificaron los parámetros críticos del pipeline: la condición operacional de trabajo, el tipo de señal de entrada, el dominio de representación y el nivel de solapamiento entre ventanas.

3.1 SEÑALES DISPONIBLES

Cada experimento del dataset contiene tres canales de señal relevantes para este proyecto: **Corriente 1 (MCS-1)**, **Corriente 2 (MCS-2)** y **Vibración**. Las señales de corriente presentan una portadora dominante a la frecuencia de red (50 Hz) con modulaciones de baja amplitud asociadas a las frecuencias características de falla (BPFO, BPFI).

3.2 IMPACTO DEL DOMINIO DE REPRESENTACIÓN

Una de las observaciones clave del EDA fue que trabajar con la señal de corriente cruda en el dominio del tiempo produce representaciones muy similares entre clases, dificultando la discriminación. Al transformar la señal al dominio de la frecuencia mediante la **Transformada Rápida de Fourier (FFT) en escala logarítmica**, las firmas espectrales de cada clase se

vuelven más distinguibles, lo que justifica su adopción como representación principal en los experimentos.

3.3 ESTRATEGIA DE SEGMENTACIÓN (VENTANEO)

Dado que las señales adquiridas en el banco de pruebas de la Universidad de Paderborn presentan una naturaleza continua y de alta densidad (muestreadas a $f_s = 64$ kHz), es imperativo realizar una segmentación temporal para transformar cada archivo de serie de tiempo en un conjunto de muestras finitas aptas para el entrenamiento de la arquitectura CNN 1D. Se implementó una técnica de ventana deslizante (*Sliding Window*) sobre las señales de corriente y vibración de forma sincronizada.

Dimensionamiento de la ventana: Se seleccionó un tamaño de ventana $L = 4096$ muestras. Esta elección no es arbitraria; a la frecuencia de muestreo de 64 kHz, cada segmento representa una duración temporal de $t_w = 64$ ms. Considerando que la condición operacional analizada (N15) opera a una velocidad de rotación de 1500 rpm ($f_{rot} = 25$ Hz), el periodo de una revolución completa es de $T_{rot} = 40$ ms. Por lo tanto, cada ventana captura aproximadamente 1.6 ciclos mecánicos del eje, garantizando que los patrones periódicos asociados a las frecuencias características de falla de los rodamientos queden representados íntegramente en el dominio del tiempo antes de su transformación espectral.

Solapamiento e Independencia Estadística: Para balancear la cantidad de datos disponibles y la independencia entre muestras, se evaluó un esquema de solapamiento del 25 %. Matemáticamente, esto implica un avance o *stride* (S) calculado como:

$$S = L \times (1 - \text{Overlap}) = 4096 \times 0,75 = 3072 \text{ muestras} \quad (3.1)$$

Esta configuración permite una expansión del dataset (Data Augmentation) al generar múltiples observaciones a partir de un único registro de larga duración. Al reducir el solapamiento al 25 % (en comparación con el estándar del 50 %), se busca mitigar la redundancia de información entre ventanas adyacentes, obligando a la red neuronal a generalizar patrones de falla más robustos y menos dependientes de la continuidad de la señal.

Homogeneidad del Tensor de Entrada: El proceso de ventaneo culmina con la consolidación de un tensor de dimensiones (M, C, L) , donde M representa el número total de ventanas

extraídas, C el número de canales (Fase 1, Fase 2 y Vibración) y L la longitud de 4096 muestras. Cada ventana hereda la etiqueta del rodamiento de origen, permitiendo un entrenamiento supervisado basado en la tabla de selección de rodamientos de Lessmeier et al. [1].

3.4 ANÁLISIS DE CORRELACIÓN ENTRE CANALES DE SEÑAL

Con el objetivo de cuantificar la redundancia y complementariedad de los tres canales de entrada (**Corriente 1**, **Corriente 2** y **Vibración**), se realizó un análisis de correlación de Pearson en el dominio de la FFT logarítmica. Para cada ventana, cada canal se representa como un vector de 2049 coeficientes espectrales (resultado de la `rfft` sobre $L = 4096$ muestras), y la correlación entre pares de canales se calcula como un escalar $r \in [-1, 1]$ que cuantifica la similitud lineal entre sus espectros.




Figura 1: Distribución de la correlación de Pearson inter-canal por clase en el dominio FFT logarítmico. Se muestran los tres pares posibles: C1 vs C2, C1 vs Vibración y C2 vs Vibración. Las líneas horizontales de referencia indican $r = 0,95$ (rojo) y $r = 0,80$ (naranja).




Figura 2: Matrices de correlación promedio 3×3 entre los tres canales de señal, calculadas sobre $n = 500$ ventanas por clase en el dominio FFT logarítmico.

Los resultados, resumidos en la Tabla 1, revelan dos comportamientos cualitativamente distintos según el par de canales analizado.

Cuadro 1: Correlación de Pearson mediana entre pares de canales por clase (dominio FFT logarítmico).

Par de canales	Sano	Daño Interno	Daño Externo
Corriente 1 vs Corriente 2	0.628	0.619	0.610
Corriente 1 vs Vibración	0.145	0.251	0.256
Corriente 2 vs Vibración	0.091	0.242	0.243

Par Corriente 1 – Corriente 2: La correlación inter-canal se mantiene prácticamente constante en $r \approx 0,62$ independientemente de la condición del rodamiento (variación de apenas 0.018 entre clases). Los violines de las tres clases son morfológicamente idénticos, con distribuciones que se solapan completamente en el histograma. Esto indica que la relación espectral entre ambas fases de corriente **no aporta información discriminativa** para la clasificación. No obstante, con $r < 0,95$ ambos canales conservan aproximadamente un 38 % de varianza no compartida, por lo que su uso conjunto sigue siendo justificado al capturar patrones espectrales complementarios de la misma fuente física.

Pares Corriente – Vibración: El comportamiento es cualitativamente opuesto. En la condición sana, la correlación entre las señales de corriente y la señal de vibración es casi nula ($r = 0,145$ y $r = 0,091$ respectivamente), lo que refleja que ambas modalidades son prácticamente independientes cuando el rodamiento opera correctamente. Sin embargo, bajo condición de falla, esta correlación **se incrementa en un factor de 1.7 a 2.7**, alcanzando $r \approx 0,25$ para ambas clases de daño. Este fenómeno tiene una interpretación física directa: los impactos mecánicos periódicos generados por la falla del rodamiento producen oscilaciones en el par motor que se propagan y quedan impresas como perturbaciones moduladas en la corriente eléctrica, estableciendo un acoplamiento dinámico entre dominios que no existe en operación normal.

Limitación discriminativa entre tipos de falla: Un hallazgo relevante es que la correlación Corriente–Vibración **no distingue entre Daño Interno y Daño Externo**: los valores medianos difieren en menos de 0.005 (0.251 vs 0.256 para C1–Vib, 0.242 vs 0.243 para C2–Vib). Esto implica que, si bien la correlación inter-canal permite separar la condición sana de la condición de falla, la diferenciación entre tipos de falla dependerá de patrones espectrales más finos aprendidos por la CNN, particularmente de las frecuencias características BPFI y BPFO que se manifiestan en cada canal de forma independiente.

En conjunto, estos resultados justifican la arquitectura de entrada multi-canal adoptada: los tres canales son complementarios (ningún par alcanza $r > 0,90$), el canal de vibración introduce información de una modalidad física distinta, y la variación observada en la correlación Corriente–Vibración entre condición sana y condición de falla constituye un indicador implícito del estado del sistema que la red neuronal puede explotar durante el entrenamiento.

4

METODOLOGÍA

4.1 PROTOCOLO DE VALIDACIÓN LOBO

Se adoptó la validación cruzada por rodamiento (*Leave-One-Bearing-Out*, LOBO): en cada *fold*, los 15 experimentos asociados a un rodamiento físico se reservan íntegramente para prueba, y el modelo se entrena con el resto. Este protocolo garantiza que el clasificador deba generalizar a una instancia física completamente nueva, midiendo robustez real en lugar de memorización de firmas individuales.

La distinción entre una partición aleatoria de ventanas y una partición LOBO es central para el proyecto: en el primer caso, fragmentos del mismo rodamiento aparecen simultáneamente en entrenamiento y prueba, produciendo estimaciones de generalización artificialmente optimistas. En el segundo caso, el modelo debe demostrar que aprendió la firma física de la falla y no las características particulares de un motor específico.

4.2 ARQUITECTURA DE LA RED

La arquitectura base utilizada en todos los experimentos es una **CNN 1D de tres canales** (Corriente 1 + Corriente 2 + Vibración), estructurada de la siguiente forma:

- **Entrada:** tensor de forma $[B \times 3 \times 2049]$, donde B es el tamaño del lote y 2049 es el número de componentes espectrales por canal tras la FFT.
- **Tres bloques convolucionales 1D**, cada uno compuesto por: convolución 1D $\rightarrow$ Batch Normalization $\rightarrow$ activación ReLU $\rightarrow$ MaxPooling.
- **Capas densas con Dropout** para reducir el sobreajuste.
- **Capa de salida:** tres neuronas con activación softmax, correspondientes a las clases Sano, Daño Interno y Daño Externo.

4.3 CONFIGURACIÓN DE ENTRENAMIENTO

Los hiperparámetros utilizados en la configuración final del pipeline son los siguientes:

Cuadro 2: Hiperparámetros de entrenamiento

Parámetro	Valor
Optimizador	Adam con <i>weight decay</i>
Épocas	60
Tamaño de lote	128
Scheduler	StepLR
Normalización	Por canal, solo sobre conjunto de entrenamiento
Manejo del desbalance	Pesos de clase balanceados

5

EVOLUCIÓN EXPERIMENTAL

El desarrollo del pipeline fue incremental. Cada fase corrigió o amplió a la anterior, permitiendo identificar qué decisiones metodológicas impactaban más en el desempeño del clasificador.

5.1 PRIMERA PRUEBA: CNN 1D SOBRE SEÑAL CRUDA

Se utilizó una arquitectura CNN 1D muy sencilla sobre la señal MCS en el dominio del tiempo, con solo 10 épocas de entrenamiento, sin dropout y sin ningún mecanismo de regularización. El resultado fue una *accuracy* en validación LOBO de aproximadamente **16 %**, evidenciando que la señal cruda en el dominio temporal no ofrece suficiente discriminación entre clases bajo este protocolo de evaluación.

5.2 SEGUNDA PRUEBA: INCORPORACIÓN DE FFT LOGARÍTMICA

Se mantuvo la arquitectura CNN 1D pero la señal de entrada pasó previamente por una FFT de magnitud en escala logarítmica. El entrenamiento se amplió a 60 épocas. Este cambio de representación elevó el rendimiento a aproximadamente **40 %** en LOBO, confirmando que llevar la señal al dominio de frecuencia sí aporta información discriminante para la clasificación.

5.3 TERCERA PRUEBA: REGULARIZACIÓN Y CORRECCIONES DE ENTRENAMIENTO

Conservando la FFT como representación, se añadieron mecanismos de regularización (dropout), pesos de clase balanceados y un scheduler de tasa de aprendizaje. El rendimiento subió

a aproximadamente **51 %** en LOBO, confirmando que el problema no residía únicamente en la arquitectura sino también en la estrategia de entrenamiento.

5.4 CUARTA PRUEBA: FUSIÓN DE SENSORES SIN FFT

Se incorporó la señal de vibración como canal adicional, pero sin aplicar FFT, con el fin de evaluar si añadir una fuente de información complementaria compensaba la ausencia de transformación al dominio frecuencial. El resultado fue **49.2 %** en LOBO, indicando que la fusión de sensores aporta información útil, pero no sustituye el beneficio de trabajar en el dominio de frecuencia.

5.5 QUINTA PRUEBA: REDUCCIÓN DEL SOLAPAMIENTO AL 25 %

Con el objetivo de evaluar el impacto de la redundancia entre ventanas sobre la capacidad de generalización del modelo, se repitió la configuración de la tercera prueba (CNN 1D + FFT logarítmica + regularización) reduciendo el solapamiento de 50 % a **25 %**. Esta modificación disminuye el número total de ventanas generadas, pero aumenta la independencia estadística entre muestras adyacentes. El resultado global fue de **51.3 %** en prueba LOBO, comparable al 50 % de solapamiento, aunque se observaron mejoras puntuales en rodamientos específicos de daño interno (KI14 y KI18), lo que sugiere que una menor redundancia puede favorecer la extracción de características espectrales más distintivas en ciertos casos.

5.6 SEXTA PRUEBA: FUSIÓN DE SENSORES CON FFT LOGARÍTMICA

Como extensión natural de las pruebas cuatro y cinco, se combinó la fusión de corriente y vibración **con la transformación al dominio de la frecuencia (FFT logarítmica)**. Esta configuración busca aprovechar simultáneamente la riqueza informativa del espectro de frecuencias y la complementariedad entre ambos tipos de señal. Los resultados de esta prueba se presentan en la Sección 6.6.

5.7 RESUMEN DE LA EVOLUCIÓN

RESULTADOS EXPERIMENTALES Y ANÁLISIS

En esta sección se presentan en detalle los resultados de las configuraciones evaluadas. Para cada experimento se reportan la *accuracy* global, el comportamiento por rodamiento (histograma

Cuadro 3: Evolución del desempeño por prueba experimental

Configuración	Acc. Train (%)	Acc. LOBO (%)
CNN 1D + señal cruda (10 épocas, sin regularización)	—	≈16
CNN 1D + FFT log (60 épocas)	97.9	≈40
CNN 1D + FFT log + dropout + pesos de clase	97.9	≈51
CNN 1D + Fusión (corriente + vibración) sin FFT	100.0	49.2
CNN 1D + FFT log + dropout + pesos de clase (25 % solapam.)	96.6	51.3
CNN 1D + Fusión (corriente + vibración) con FFT	—	—

LOBO) y la matriz de confusión acumulada sobre los 15 *folds*.

6.1 MODELOS DE REFERENCIA (BASELINE)

Como punto de partida, la Tabla 4 presenta los resultados de modelos clásicos de aprendizaje automático reportados en la literatura para el mismo dataset y protocolo LOBO. El SVM constituye el mejor modelo de referencia con un 68.5 % en prueba, mientras que los modelos basados en árbol y bosque aleatorio presentan sobreajuste severo (100 % en entrenamiento frente a menos del 67 % en prueba).

Cuadro 4: Comparativa de modelos clásicos reportados en el paper original [lessmeier2016]

Modelo	Características	Acc. Train (%)	Acc. LOBO (%)
Decision Tree	Tiempo/Frecuencia (manuales)	100.0	47.1
SVM	Tiempo/Frecuencia (manuales)	88.3	68.5
k-NN	Tiempo/Frecuencia (manuales)	79.1	55.6
Random Forest	Tiempo/Frecuencia (manuales)	100.0	66.1

6.2 EXPERIMENTO 2: CNN 1D + FFT LOG (50 % SOLAPAMIENTO)

Tabla Comparativa: Modelos Clásicos vs Nuestra CNN 1D (FFT Log)			
Modelo	Features	Acc. Train (%)	Acc. LOBO Test (%)
Decision Tree (Paper)	Time/Freq (Handcrafted)	100.0	47.1
SVM (Paper)	Time/Freq (Handcrafted)	88.3	68.5
k-NN (Paper)	Time/Freq (Handcrafted)	79.1	55.6
Random Forest (Paper)	Time/Freq (Handcrafted)	100.0	66.1
NUESTRA CNN 1D (FFT Log)	Frequency Spectrum (Log)	91.9	45.6

Figura 3: Tabla comparativa de resultados del Experimento 2: CNN 1D + FFT Log (50 % solapamiento).




Figura 4: Matriz de confusión del Experimento 2: CNN 1D + FFT Log (50 % solapamiento).

6.3 EXPERIMENTO 3: CNN 1D + FFT LOG + DROPOUT + PESOS DE CLASE

Se procesó la señal de corriente mediante FFT logarítmica con un solapamiento del 50 % entre ventanas.

- **Desempeño global:** 97.9 % de *accuracy* en entrenamiento y **51.7 %** en prueba LOBO, evidenciando un fuerte sobreajuste.
- **Análisis por clase:** La matriz de confusión (Figura 7) revela que el modelo clasifica correctamente la mayoría de muestras sanas, pero presenta una confusión crítica entre daño interno y daño externo, con más de 20,000 muestras cruzadas entre ambas clases de falla.
- **Comportamiento por rodamiento:** Los rodamientos K001 (Sano), KI16 y KI18 (Interno) presentaron precisiones superiores al 97 %. Sin embargo, K002, KI04 y KI21 reportaron un 0 % de *accuracy*, indicando que sus firmas espectrales difieren significativamente del resto del conjunto de entrenamiento.

Tabla Comparativa: Modelos Clásicos vs CNN 1D + FFT Log (Corregida)

Modelo	Features	Acc. Train (%)	Acc. LOBO Test (%)
Decision Tree (Paper)	Time/Freq (Handcrafted)	100.0	47.1
SVM (Paper)	Time/Freq (Handcrafted)	88.3	68.5
k-NN (Paper)	Time/Freq (Handcrafted)	79.1	55.6
Random Forest (Paper)	Time/Freq (Handcrafted)	100.0	66.1
CNN 1D + FFT Log (Corregida)	Frequency Spectrum (Log)	97.9	51.7




Figura 5: Experimento 3 — Matriz de confusión, histograma LOBO y convergencia del entrenamiento (CNN 1D + FFT Log, 50 % solapamiento).




Figura 6: Experimento 3 — Matriz de confusión, histograma LOBO y convergencia del entrenamiento (CNN 1D + FFT Log, 50 % solapamiento).




Figura 7: Experimento 3 — Matriz de confusión, histograma LOBO y convergencia del entrenamiento (CNN 1D + FFT Log, 50 % solapamiento).

6.4 EXPERIMENTO 4: FUSIÓN DE SENSORES (CORRIENTE + VIBRACIÓN, SIN FFT)

Se implementó una arquitectura de fusión de sensores procesando simultáneamente las señales de corriente y vibración sin transformación al dominio frecuencial.

- **Convergencia:** Este modelo presentó la convergencia más rápida, estabilizando la pérdida cerca de 0.001 antes de la época 10.
- **Desempeño global:** 100 % en entrenamiento y **49.2 %** en prueba LOBO.
- **Impacto de la fusión:** La incorporación de la señal de vibración mejoró drásticamente la detección de la clase “Sano”, pero la discriminación entre tipos de daño no mejoró respecto a la señal de corriente aislada, manteniendo una alta tasa de error en KA30 y KI04.

Tabla Comparativa: Modelos Clásicos vs Fusión de Sensores

Modelo	Features	Acc. Train (%)	Acc. LOBO Test (%)
Decision Tree (Paper)	Time/Freq (Handcrafted)	100.0	47.1
SVM (Paper)	Time/Freq (Handcrafted)	88.3	68.5
k-NN (Paper)	Time/Freq (Handcrafted)	79.1	55.6
Random Forest (Paper)	Time/Freq (Handcrafted)	100.0	66.1
CNN 1D Fusión (32-Bits)	Corriente+Vibración (Log)	100.0	49.2




Figura 8: Experimento 4 — Resultados de la fusión de sensores corriente + vibración sin FFT.




Figura 9: Experimento 4 — Resultados de la fusión de sensores corriente + vibración sin FFT.




Figura 10: Experimento 4 — Resultados de la fusión de sensores corriente + vibración sin FFT.

6.5 EXPERIMENTO 5: CNN 1D + FFT LOG (25 % SOLAPAMIENTO)

Para evaluar el impacto de la redundancia de datos, se redujo el solapamiento al 25 %.

- **Desempeño global:** 96.6 % en entrenamiento y **51.3 %** en prueba LOBO.

- **Observaciones:** Aunque el resultado global es similar al del 50 %, se observó una ligera mejora en la clasificación de ciertos rodamientos de daño interno (KI14 alcanzó 91 % y KI18 un 95 %), lo que sugiere que un menor solapamiento puede capturar características espectrales más distintivas en determinados casos de falla.

Tabla Comparativa: Modelos Clásicos vs CNN 1D + FFT Log (Corregida)

Modelo	Features	Acc. Train (%)	Acc. LOBO Test (%)
Decision Tree (Paper)	Time/Freq (Handcrafted)	100.0	47.1
SVM (Paper)	Time/Freq (Handcrafted)	88.3	68.5
k-NN (Paper)	Time/Freq (Handcrafted)	79.1	55.6
Random Forest (Paper)	Time/Freq (Handcrafted)	100.0	66.1
CNN 1D + FFT Log (Corregida)	Frequency Spectrum (Log)	96.6	51.3




Figura 11: Experimento 5 — CNN 1D + FFT Log con 25 % de solapamiento.




Figura 12: Experimento 5 — CNN 1D + FFT Log con 25 % de solapamiento.




Figura 13: Experimento 5 — CNN 1D + FFT Log con 25 % de solapamiento.

6.6 EXPERIMENTO 6: FUSIÓN DE SENSORES (CORRIENTE + VIBRACIÓN) CON FFT LOGARÍTMICA

Esta configuración integra las dos mejoras más relevantes identificadas en los experimentos anteriores: la transformación al dominio de la frecuencia mediante FFT logarítmica y la fusión de canales de corriente y vibración. La hipótesis es que combinar ambas estrategias permitirá al modelo aprovechar simultáneamente la discriminación espectral de la FFT y la información complementaria del acelerómetro, superando las limitaciones individuales de cada enfoque.

- **Desempeño global:** 100 % de *accuracy* en entrenamiento y **49.0 %** en prueba LOBO, resultado inferior al Experimento 5 (51.3 %) y al Experimento 3 (51.7 %), ambos operando únicamente con señales de corriente. La adición del canal de vibración con transformación FFT logarítmica no produjo la mejora sinérgica esperada; por el contrario, incrementó la capacidad de memorización del modelo sin aportar generalización adicional.
- **Análisis por clase:** La matriz de confusión acumulada (Figura ??) revela un deterioro severo en la discriminación entre clases de falla. La clase *Sano* mantiene un recall aceptable ($\approx 79,5$ %), con solo 190 muestras mal clasificadas como Daño Interno. Sin embargo, la clase Daño Interno presenta un colapso crítico: de las 32,400 muestras totales, más de 20,200 son clasificadas erróneamente como Daño Externo, resultando en un recall de apenas 37.6 %. La clase Daño Externo exhibe el peor desempeño del experimento, con un recall de 29.3 %: cerca de 4,844 muestras son asignadas a Sano y 17,966 a Daño Interno, lo que

sugiere que la red neuronal no logra construir una frontera de decisión estable para esta clase cuando se combina el espectro de vibración con el de corriente bajo solapamiento del 25 %.

- **Comportamiento por rodamiento:** El histograma LOBO (Figura ??) muestra una distribución bimodal de desempeño. Los rodamientos sanos K001, K003, K004 y K005 alcanzan accuracies superiores al 92 %, mientras que KI18 (87 %) y KI16 (56 %) continúan siendo los rodamientos de daño interno con mejor detección. Los casos críticos persisten e incluso se agravan respecto al Experimento 5: KA30 y KI04 mantienen 0 %, K002 cae a 8 %, KA15 y KA16 registran 8 %, y KI21 permanece en 0 %. Notablemente, KA22 regresa a 37 % tras haber alcanzado 39 % en el experimento anterior, y KI14 cae de 91 % a 44 %, lo que representa la pérdida más significativa de generalización respecto a la configuración de corriente sola con 25 % de solapamiento.

Tabla Comparativa: Modelos Clasicos vs CNN 1D + FFT Log (3 Canales)

Modelo	Features	Acc. Train (%)	Acc. LOBO Test (%)
Decision Tree (Paper)	Time/Freq (Handcrafted)	100.0	47.1
SVM (Paper)	Time/Freq (Handcrafted)	88.3	68.5
k-NN (Paper)	Time/Freq (Handcrafted)	79.1	55.6
Random Forest (Paper)	Time/Freq (Handcrafted)	100.0	66.1
CNN 1D + FFT Log (3 Canales)	FFT Log (Corriente x2 + Vibracion)	100.0	49.0




Figura 14: Histograma LOBO del Experimento 6: Fusión de sensores (corriente + vibración) con FFT logarítmica.




Figura 15: Convergencia del entrenamiento en el Experimento 6: Fusión de sensores (corriente + vibración) con FFT logarítmica.




Figura 16: Matriz de confusión del Experimento 6: Fusión de sensores (corriente + vibración) con FFT logarítmica.

6.7 DISCUSIÓN GENERAL DE HALLAZGOS

A partir de las configuraciones evaluadas se extraen las siguientes conclusiones técnicas:

1. **Memorización vs. aprendizaje:** La brecha de casi 50 puntos porcentuales entre *accuracy* de entrenamiento y prueba LOBO confirma que la CNN está memorizando características específicas de los rodamientos individuales en lugar de aprender patrones físicos universales de falla. Este hallazgo valida el diseño experimental propuesto y su énfasis en el protocolo LOBO.

2. **Rodamientos atípicos:** Los rodamientos **K002**, **KI04** y **KI21** representan valores atípicos consistentes en todas las configuraciones probadas. Sus señales parecen contener ruidos o armónicos no representados en el resto del conjunto de entrenamiento, lo que los convierte en instancias de alta varianza para el clasificador.
3. **Impacto de la representación:** La FFT logarítmica produce una mejora clara respecto a la señal cruda ($\approx 16\%$ vs. $\approx 51\%$), confirmando la hipótesis de que llevar la señal al dominio de frecuencia expone patrones más discriminantes para la red.
4. **Fusión de sensores:** La incorporación de la señal de vibración mejora la identificación del estado sano, pero no resuelve la confusión entre daño interno y externo. Esto indica que el cuello de botella es la representación, no la cantidad de canales.
5. **Solapamiento:** La reducción del solapamiento al 25% no produjo una mejora global significativa, aunque sí benefició a rodamientos específicos de daño interno, sugiriendo que la independencia entre muestras puede ser relevante para ciertos subgrupos.
6. **Fusión con FFT logarítmica como retroceso:** El Experimento 6 contradice la hipótesis de complementariedad entre el espectro de vibración y el de corriente. Al incorporar el canal de vibración transformado al dominio frecuencial, el modelo dispone de un vector de entrada tres veces más rico en dimensionalidad, pero el resultado en prueba LOBO desciende 2.3 puntos porcentuales respecto al Experimento 5. La explicación más plausible es la *maldición de la dimensionalidad espectral*: el espectro de vibración contiene firmas físicas muy específicas de cada rodamiento individual (resonancias estructurales, ruidos de montaje, características del banco de pruebas) que no generalizan a instancias nuevas. Esta información, lejos de complementar la firma de corriente, introduce variabilidad espuria que el modelo aprende a memorizar. El resultado refuerza la conclusión del Experimento 4: el cuello de botella no es la cantidad de canales ni la riqueza de representación, sino la naturaleza altamente idiomática de las firmas de cada rodamiento físico bajo el protocolo LOBO.

INDICADORES DE DESEMPEÑO POR EXPERIMENTO

A partir de las matrices de confusión acumuladas sobre los 15 folds LOBO se calcularon cinco indicadores por clase: accuracy global, precisión, sensibilidad (recall), tasa de error y tasa de falsos positivos (FPR). La tasa de falsos positivos se define como $FPR = FP / (FP + TN)$, es decir, la proporción de muestras que no pertenecen a una clase pero que el modelo asigna erróneamente a ella.

Experimento 2: CNN 1D + FFT Log (50 % solapamiento)

Cuadro 5: Indicadores de desempeño por clase — Experimento 2

Clase	Accuracy	Precisión	Sensibilidad	Tasa de Error	FPR
Sano	0.408	0.737	0.618	0.592	0.110
Daño Interno		0.359	0.436		0.389
Daño Externo		0.180	0.170		0.389

Con solo FFT logarítmica y sin regularización el modelo discrimina la clase Sano con cierta fiabilidad (precisión 0.737), pero las clases de falla quedan muy por debajo. Daño Externo tiene una sensibilidad de apenas 0.170: el modelo pasa por alto ocho de cada diez ventanas con falla externa. La FPR de Daño Interno y Daño Externo ronda 0.389 en ambos casos, lo que significa que cerca de cuatro de cada diez muestras de otras clases son mal asignadas a esas categorías.

Experimento 3: CNN 1D + FFT Log + *dropout* + pesos de clase

Cuadro 6: Indicadores de desempeño por clase — Experimento 3

Clase	Accuracy	Precisión	Sensibilidad	Tasa de Error	FPR
Sano	0.517	0.785	0.574	0.483	0.079
Daño Interno		0.457	0.549		0.326
Daño Externo		0.402	0.429		0.320

La regularización produce la mejora más consistente del pipeline. La FPR de Sano baja de 0.110 a 0.079 y la de Daño Externo cae de 0.389 a 0.320. La sensibilidad de Daño Interno sube de 0.436 a 0.549 y la precisión de Daño Externo casi se duplica respecto al Experimento 2 (de 0.180 a 0.402). La tasa de error global cae de 0.592 a 0.483, la más baja de todos los experimentos evaluados.

Experimento 4: Fusión de sensores (corriente + vibración, sin FFT)

Cuadro 7: Indicadores de desempeño por clase — Experimento 4

Clase	Accuracy	Precisión	Sensibilidad	Tasa de Error	FPR
Sano	0.493	0.796	0.808	0.508	0.103
Daño Interno		0.429	0.397		0.264
Daño Externo		0.257	0.272		0.394

La fusión sin FFT tiene la sensibilidad más alta en Sano de todos los experimentos (0.808), lo que confirma que la vibración en crudo aporta información útil para detectar funcionamiento normal. Sin embargo, Daño Externo retrocede: su sensibilidad baja a 0.272 y su FPR sube a 0.394, prácticamente igual al Experimento 2. Agregar un canal sin transformación frecuencial no ayuda a separar los tipos de falla.

Experimento 5: CNN 1D + FFT Log (25 % solapamiento)

Cuadro 8: Indicadores de desempeño por clase — Experimento 5

Clase	Accuracy	Precisión	Sensibilidad	Tasa de Error	FPR
Sano	0.513	0.871	0.576	0.487	0.043
Daño Interno		0.443	0.560		0.352
Daño Externo		0.374	0.402		0.337

Reducir el solapamiento al 25 % tiene un efecto directo sobre la clase Sano: la precisión sube a 0.871 (el valor más alto de todos los experimentos en esa clase) y la FPR cae a 0.043, lo que significa que menos del 5 % de las muestras de falla son etiquetadas erróneamente como sanas. Daño Interno mejora marginalmente en sensibilidad (0.560 vs. 0.549 del Experimento 3). La tasa de error global de 0.487 es la segunda más baja, muy próxima a la del Experimento 3.

Experimento 6: Fusión de sensores (corriente + vibración) con FFT logarítmica

Cuadro 9: Indicadores de desempeño por clase — Experimento 6

Clase	Accuracy	Precisión	Sensibilidad	Tasa de Error	FPR
Sano	0.490	0.842	0.798	0.510	0.075
Daño Interno		0.402	0.376		0.280
Daño Externo		0.265	0.296		0.410

Combinar vibración y FFT logarítmica produce la FPR más alta de todos los experimentos en Daño Externo (0.410) y la sensibilidad más baja en Daño Interno (0.376). A pesar de que la clase Sano obtiene una sensibilidad de 0.798, la accuracy global de 0.490 es la segunda más baja. El espectro de vibración añade dimensionalidad que el modelo memoriza en entrenamiento pero que no generaliza bajo LOBO.

TABLA COMPARATIVA GLOBAL DE INDICADORES DE DESEMPEÑO

La Tabla 10 consolida los cinco indicadores para los cinco experimentos. Los valores en negrita indican el mejor resultado de cada columna por clase.

Cuadro 10: Comparativa global de indicadores de desempeño (protocolo LOBO, 15 rodamientos)

Experimento	Clase	Accuracy	Precisión	Sensibilidad	Tasa de Error	FPR
Exp. 2 FFT Log 50 %	Sano		0.737	0.618		0.110
	Daño Interno	0.408	0.359	0.436	0.592	0.389
	Daño Externo		0.180	0.170		0.389
Exp. 3 FFT Log + reg.	Sano		0.785	0.574		0.079
	Daño Interno	0.517	0.457	0.549	0.483	0.326
	Daño Externo		0.402	0.429		0.320
Exp. 4 Fusión sin FFT	Sano		0.796	0.808		0.103
	Daño Interno	0.493	0.429	0.397	0.508	0.264
	Daño Externo		0.257	0.272		0.394
Exp. 5 FFT Log 25 %	Sano		0.871	0.576		0.043
	Daño Interno	0.513	0.443	0.560	0.487	0.352
	Daño Externo		0.374	0.402		0.337
Exp. 6 Fusión con FFT	Sano		0.842	0.798		0.075
	Daño Interno	0.490	0.402	0.376	0.510	0.280
	Daño Externo		0.265	0.296		0.410

$FPR = FP / (FP + TN)$. Los valores en negrita indican el mejor resultado en cada columna por clase.

Accuracy y Tasa de Error son métricas globales compartidas entre las tres clases.

CONCLUSIONES PRELIMINARES

Este primer entregable establece la línea base experimental del proyecto y permite extraer conclusiones metodológicas sólidas antes de proceder a la fase comparativa completa.

El hallazgo más relevante es que el rendimiento del clasificador depende fuertemente de la **representación de la señal** y de la **estrategia de validación**. Una partición aleatoria por ventana produciría métricas engañosamente optimistas; el protocolo LOBO expone la realidad del problema: la CNN memoriza firmas individuales de rodamiento en lugar de aprender patrones físicos generalizables. Este fenómeno está alineado con las advertencias de Lessmeier et al. [lessmeier2016], quienes fueron de los primeros en señalar esta limitación metodológica en el contexto del dataset de Paderborn.

El paso de señal cruda a FFT logarítmica resultó ser la mejora más significativa del pipeline, con una ganancia de más de 30 puntos porcentuales en prueba LOBO. La regularización (dro-

pout, pesos de clase, scheduler) añadió cerca de 10 puntos adicionales. La fusión con vibración aportó robustez para la clase sana, pero no resolvió la confusión entre tipos de daño. El experimento pendiente de fusión con FFT (Experimento 6) permitirá determinar si la combinación de ambas estrategias produce una mejora sinérgica o simplemente acumula las ganancias de cada una de forma independiente.

Para el segundo entregable, el análisis se extenderá hacia esquemas de etiquetado más finos (separación por mecanismo de daño y severidad) y se incorporarán modelos basados en vectores de características (MLP), con el fin de responder las dos preguntas centrales del proyecto: ¿qué representación generaliza mejor?, y ¿qué granularidad de etiquetas produce modelos más robustos?

REFERENCIAS

- [1] Lessmeier, C. et al. (2016). *Condition monitoring of bearing damage in electromechanical drive systems by using motor current signals of electric motors: A benchmark data set for data-driven classification*. PHM Society European Conference, Vol. 3.
- [2] Ince, T. et al. (2016). Real-time motor fault detection by 1-D convolutional neural networks. *IEEE Transactions on Industrial Electronics*, 63(11), 7067–7075.
- [3] Zhang, W., Peng, G., Li, C. (2017). Bearing fault diagnosis using convolutional neural networks with 2D representations of vibration signals as input. *Journal of Physics: Conference Series*, 364, 012051.
- [4] Hoang, D.T., Kang, H.J. (2019). A survey on Deep Learning based bearing fault diagnosis. *Neurocomputing*, 335, 327–335.