

Inteligencia Computacional

ENTREGABLE 2 — EXPLORACIÓN CON FEATURES EXTRAÍDAS

Johan Sebastián Cáceres Rodríguez
20212005111

Joel Eduardo Reyes Barrios
20212005011

6 de junio de 2026



**UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS**
Acreditación Institucional de Alta Calidad

Resumen

Este trabajo presenta la segunda etapa del proyecto de diagnóstico de fallas en rodamientos del tipo FAG 6203-2RSR utilizando el conjunto de datos *Paderborn University Bearing Data Center*. A diferencia del Entregable 1, donde se empleó la señal cruda como entrada a una CNN 1D, en este entregable se explora el paradigma de **ingeniería de características**: se extraen 272 descriptores por ventana en los dominios temporal, frecuencial y de la envolvente Hilbert. El diseño experimental es **iterativo**: cada experimento reveló limitaciones concretas del dataset o del espacio de características que motivaron ajustes en la configuración de clases y en el criterio de selección, manteniendo en todo momento el protocolo *Leave-One-Bearing-Out* (LOBO) como evaluación no negociable. Los hallazgos más relevantes son la inseparabilidad empírica del subtipo EDM entre pista interna y externa bajo LOBO, y la superioridad de la selección de características por pureza SOM (no supervisada) sobre el F-score supervisado para la generalización inter-rodamiento. El mejor resultado alcanzado es una **exactitud LOBO media del 74.3 %** con una CNN alimentada por las 30 características seleccionadas por pureza SOM.

ÍNDICE

1. Introducción	4
2. Descripción del Conjunto de Datos	4
2.1. Base de datos Paderborn	4
2.2. Ventaneo y preprocesamiento	4
2.3. Restricciones del dataset relevantes para el diseño experimental	5
2.4. Frecuencias características del rodamiento	5
3. Desarrollo	6
3.1. Extracción de Características	6
3.1.1. Bloques de características	6
3.1.2. Protocolo LOBO	6
3.2. Arquitectura del Clasificador	7
3.3. Experimento 1: CNN sobre 7 clases de subtipo de daño	7
3.3.1. Motivación	7
3.3.2. Configuración	8
3.3.3. Resultados	8
3.3.4. Diagnóstico y decisión para el experimento siguiente	9
3.4. Experimento 2: CNN con 5 clases y EDM como clase unificada	10
3.4.1. Motivación	10

3.4.2.	Configuración	10
3.4.3.	Resultados	11
3.4.4.	Diagnóstico y decisión para el experimento siguiente	11
3.5.	Experimento 3: CNN con 5 clases, sin EDM	12
3.5.1.	Motivación	12
3.5.2.	Configuración	12
3.5.3.	Resultados	12
3.6.	Experimento 4: Mapa Auto-Organizativo (SOM) como herramienta de visualización	13
3.6.1.	Motivación	13
3.6.2.	Configuración	13
3.6.3.	Resultados	14
3.7.	Experimento 5: Selección de características por Pureza SOM	15
3.7.1.	Motivación	15
3.7.2.	Método	16
3.7.3.	Resultados	16
3.8.	Experimento 6 (Final): CNN con Top-30 por Pureza SOM	16
3.8.1.	Motivación	16
3.8.2.	Configuración	17
3.8.3.	Resultados	17
3.9.	Análisis Comparativo	18
3.10.	Discusión	19
3.10.1.	El problema de la identidad del rodamiento	19
3.10.2.	Ventaja de la selección no supervisada	19
3.10.3.	Limitaciones	19

4. Conclusiones

20

1 INTRODUCCIÓN

El diagnóstico de fallas en rodamientos es un problema canónico en el área de mantenimiento predictivo. Los rodamientos de tipo FAG 6203-2RSR del banco de datos de la Universidad de Paderborn [Les+16] exhiben tres tipos de condición: sano, daño en la pista interna (IR) y daño en la pista externa (OR), inducidos por métodos artificiales (EDM, grabador eléctrico, taladro) o generados por fatiga real en condiciones de operación.

En el Entregable 1 se estableció una línea base usando una CNN 1D sobre señal cruda bajo protocolo LOBO. La principal limitación observada fue que el espacio de representaciones aprendido tendía a memorizar la identidad del rodamiento más que la condición de falla, un fenómeno documentado en la literatura [Les+16].

El presente entregable aborda ese problema desde la perspectiva de la *ingeniería de características*: en lugar de datos crudos, se calculan descriptores físicamente interpretables que, en principio, deberían ser más robustos a la variabilidad inter-rodamiento. La exploración siguió un proceso iterativo en el que los resultados de cada experimento guiaron las decisiones del siguiente. Todos los experimentos se evalúan bajo LOBO.

2 DESCRIPCIÓN DEL CONJUNTO DE DATOS

2.1 BASE DE DATOS PADERBORN

Se emplea el subconjunto del banco de datos correspondiente a rodamientos operando a 1500 rpm con carga de 1000 N y 0.7 Nm de par. Los rodamientos KB (daños mixtos) son excluidos. Cada señal es capturada a $f_s = 64,000$ Hz con tres canales simultáneos:

- **C1**: corriente de fase del motor (canal 1).
- **C2**: corriente de fase del motor (canal 2).
- **Vib**: acelerómetro de vibración radial.

2.2 VENTANEO Y PREPROCESAMIENTO

Cada registro continuo se divide en ventanas de $N = 4096$ muestras con solapamiento del 25 %, produciendo segmentos de aproximadamente 64 ms. El dataset ventaneado final cuenta con **148,125 ventanas** provenientes de 28 rodamientos, con la distribución por clase que se muestra en la Tabla 1.

Cuadro 1: Distribución de ventanas por clase y mecanismo de daño.

Clase	Rodamientos	Ventanas	%
Sano	K001–K006 ($\times 6$)	31,727	21.4 %
IR — EDM	KI01	10,594	7.2 %
IR — Grabador	KI05	5,298	3.6 %
IR — Taladro	KI04, KI07	10,582	7.1 %
IR — Fatiga real	KI03, KI14, KI16, KI18, KI21	26,472	17.9 %
OR — EDM	KA01	10,620	7.2 %
OR — Grabador	KA05	5,295	3.6 %
OR — Taladro	KA04, KA07, KA08	15,807	10.7 %
OR — Fatiga real	KA03, KA06, KA15, KA16, KA22, KA30	31,730	21.4 %
Total		148,125	100 %

2.3 RESTRICCIONES DEL DATASET RELEVANTES PARA EL DISEÑO EXPERIMENTAL

Antes de describir los experimentos, es importante señalar dos restricciones estructurales del dataset que condicionaron el diseño de los folds LOBO:

- **Subtipos de un único rodamiento:** KI05 (IR-Grabador) y KA05 (OR-Grabador) son los únicos representantes de sus respectivos subtipos. Bajo LOBO, el modelo nunca ha visto ese subtipo durante el entrenamiento cuando se evalúa ese rodamiento, haciendo la tarea estructuralmente imposible de manera justa.
- **EDM con un rodamiento por pista:** KI01 es el único rodamiento IR-EDM y KA01 el único OR-EDM. Esta escasez hace que la separación entre estos subtipos sea especialmente sensible a la variabilidad inter-rodamiento.

Estas restricciones no son decisiones de diseño de los autores: son características fijas del dataset que el proceso experimental reveló progresivamente.

2.4 FRECUENCIAS CARACTERÍSTICAS DEL RODAMIENTO

Para el FAG 6203-2RSR con $N_b = 8$ bolas, diámetro de bola $d = 6,75$ mm y diámetro de paso $D = 28,5$ mm a $f_r = 25$ Hz:

$$\text{BPFO} = \frac{N_b}{2} f_r \left(1 - \frac{d}{D} \right) \approx 76,4 \text{ Hz} \quad (2.1)$$

$$\text{BPFI} = \frac{N_b}{2} f_r \left(1 + \frac{d}{D} \right) \approx 123,6 \text{ Hz} \quad (2.2)$$

Estas frecuencias se emplean directamente en la construcción de las características espectrales de falla.

3 DESARROLLO

3.1 EXTRACCIÓN DE CARACTERÍSTICAS

3.1.1. Bloques de características

Se extraen **272 características** por ventana, organizadas en cuatro bloques que operan sobre cada uno de los tres canales (C1, C2, Vib):

Bloque temporal. Estadísticos clásicos que capturan la forma de la distribución de amplitudes: RMS, kurtosis, factor de cresta, factor de forma, asimetría, curtosis de la envolvente Hilbert.

Bloque frecuencial — FFT con bandas logarítmicas. El espectro de magnitud $|X(f)|$ se divide en 32 bandas de igual ancho logarítmico entre 0 Hz y la frecuencia de Nyquist. Por cada banda se calcula la energía normalizada respecto al total, produciendo un descriptor de distribución espectral independiente de la amplitud absoluta.

Bloque de frecuencias características (BPFO/BPFI). Energía acumulada en ventanas espectrales de ± 5 Hz centradas en BPFO, BPFI y sus dos primeros armónicos; razón BPFI/BPFO; razón entre armónicos; centroide espectral normalizado.

Bloque de envolvente Hilbert. Sobre la señal analítica $\hat{x}(t) = x(t) + j\mathcal{H}\{x(t)\}$ se calculan la kurtosis de la envolvente, la energía espectral de la envolvente en las frecuencias BPFO y BPFI, y descriptores de regulación de la modulación de amplitud.

Bloque Wavelet Packet (WPD). Descomposición en paquetes wavelet de nivel 4 con wavelet db4. Para cada uno de los $2^4 = 16$ nodos terminales se calcula la energía relativa, aportando resolución tiempo-frecuencia adaptativa.

3.1.2. Protocolo LOBO

Dado que el dataset presenta variabilidad inter-rodamiento significativa (distintas geometrías nominales, historias de fatiga y condiciones de montaje), se emplea el protocolo **Leave-One-**

Bearing-Out (LOBO): en cada fold, todas las ventanas de *un único rodamiento* se reservan para test, y el modelo se entrena con los datos del resto. Este protocolo es el único que garantiza que el clasificador generaliza a rodamientos completamente nuevos, sin filtración de información entre train y test.

3.2 ARQUITECTURA DEL CLASIFICADOR

Se emplea una CNN 1D que recibe el vector de características como una “señal” de longitud K en un único canal:

$$\mathbf{x} \in \mathbb{R}^{1 \times K} \quad (3.1)$$

La arquitectura consta de tres bloques convolucionales seguidos de capas densas, tal como se resume en la Tabla 2.

Cuadro 2: Arquitectura CNN 1D sobre vector de características.

Capa	Detalle	Activación	Regularización
Conv1D (1→64)	kernel=7, padding=3	ReLU + BN	—
MaxPool1D	kernel=2	—	—
Conv1D (64→128)	kernel=5, padding=2	ReLU + BN	—
MaxPool1D	kernel=2	—	—
Conv1D (128→256)	kernel=3, padding=1	ReLU + BN	—
GlobalAvgPool1D	—	—	—
Dense (256→128)	—	ReLU	Dropout 40 %
Dense (128→64)	—	ReLU	Dropout 24 %
Dense (64→ C)	C = núm. clases	Softmax	—

El entrenamiento usa AdamW con $lr = 0,001$ y *weight decay* 10^{-4} , 50 épocas con *cosine annealing*, lotes de 256 y pesos de clase balanceados (`compute_class_weight`). La normalización se realiza con `RobustScaler` ajustado *únicamente* sobre los datos de train.

3.3 EXPERIMENTO 1: CNN SOBRE 7 CLASES DE SUBTIPO DE DAÑO

3.3.1. Motivación

La hipótesis de partida fue que separar los mecanismos de inducción de daño (EDM, taladro, fatiga) podría producir clases más cohesivas y mejorar la discriminación respecto a las tres clases clásicas del Entregable 1. Esta granularidad más fina es también más informativa desde el punto de vista del mantenimiento predictivo.

3.3.2. Configuración

Se definen 7 clases: Sano, IR-EDM, IR-Fatiga, IR-Taladro, OR-EDM, OR-Fatiga, OR-Taladro. Los rodamientos de grabador eléctrico (KI05, KA05) se excluyen porque existe un único rodamiento por subtipo, lo que hace inviable el protocolo LOBO (el modelo nunca habría visto ese subtipo en entrenamiento). El conjunto de evaluación comprende 9 folds con los rodamientos descritos en la Tabla 3.

Cuadro 3: Rodamientos de test en cada fold — Experimento 7 clases.

Fold	Rodamiento test	Clase / Subtipo	Rods. en train
1	K001	Sano	25
2	K003	Sano	25
3	K004	Sano	25
4	KI01	IR — EDM	25
5	KI14	IR — Fatiga	25
6	KI04	IR — Taladro	25
7	KA02	OR — EDM	25
8	KA15	OR — Fatiga	25
9	KA04	OR — Taladro	25

3.3.3. Resultados




Figura 1: Exactitud LOBO por rodamiento evaluado — Experimento 7 clases. Colores por clase evaluada. La línea punteada roja indica el nivel de azar (14.3%).




Figura 2: Matriz de confusión global acumulada del Experimento 7 clases (9 folds).

La exactitud media es de 35.5 %, y el análisis de la matriz de confusión revela el hallazgo más relevante del experimento:

- **IR-EDM (KI01) se clasifica como OR-EDM** en el 65 % de los casos. La firma de la descarga por EDM domina la representación independientemente de si el daño está en la pista interna o externa.
- **OR-EDM (KA02) se clasifica como IR-EDM** en el 84 % de los casos. La confusión es simétrica, confirmando que EDM genera una firma espectral característica que el modelo no puede asociar a una ubicación de falla bajo LOBO.
- **OR-Fatiga actúa como “clase basura”**: absorbe los errores de las clases de daño con menor soporte en entrenamiento, reflejando el sesgo hacia la clase mayoritaria (6 rodamientos en train).

3.3.4. Diagnóstico y decisión para el experimento siguiente

El modelo aprende el *mecanismo de inducción del daño* mejor que la *ubicación del daño*. EDM produce impactos de alta energía con una firma espectral tan dominante que supera la

información de localización (BPFO vs. BPFI) bajo el protocolo LOBO.

Este resultado no fue buscado para mejorar métricas: fue una observación empírica de la matriz de confusión. La decisión de modificar la taxonomía de clases en el Experimento 2 responde directamente a este hallazgo: si IR-EDM y OR-EDM son indistinguibles entre sí, mantenerlos como clases separadas introduce ruido en la evaluación sin aportar información diagnóstica.

3.4 EXPERIMENTO 2: CNN CON 5 CLASES Y EDM COMO CLASE UNIFICADA

3.4.1. Motivación

Dado que el Experimento 1 reveló que IR-EDM y OR-EDM son indistinguibles bajo LOBO, se propone una reformulación coherente con esa observación: unificar ambos subtipos EDM en una única clase independiente de la ubicación del daño (“EDM”), y evaluar si las clases restantes resultan más discriminables.

3.4.2. Configuración

Cinco clases: Sano, IR (fatiga + taladro unificados), EDM (IR y OR juntos), OR-Desgaste (fatiga), OR-Taladro. Se evalúan 5 folds LOBO: K003 (Sano), KI01 (IR), KA09 (OR-EDM), KA22 (OR-Desgaste), KA07 (OR-Taladro). Se emplean las Top-80 características seleccionadas por F-score supervisado.

3.4.3. Resultados




Figura 3: Exactitud LOBO por rodamiento — CNN Top-80 con 5 clases y EDM como clase unificada. Media: 60.4 %.

El rodamiento KA09 (EDM) obtiene 0.0 %, lo que reveló un segundo problema estructural: aunque unificamos IR-EDM y OR-EDM, el modelo nunca aprende a identificar esa clase frente a un rodamiento EDM nuevo porque la variabilidad inter-rodamiento dentro de la propia clase EDM es alta (recordemos: solo hay dos rodamientos EDM en el dataset). Los resultados de las demás clases son razonables (IR: 63.5 %, OR-Taladro: 79.7 %, OR-Desgaste: 58.9 %).

3.4.4. Diagnóstico y decisión para el experimento siguiente

El 0.0 % en EDM no es una falla del clasificador sino una consecuencia estructural del dataset: con un único rodamiento por subtipo EDM, el protocolo LOBO no puede evaluar la generalización de forma justa. La clase EDM, aunque físicamente coherente, no es evaluable bajo LOBO con los rodamientos disponibles. Por lo tanto, la decisión de eliminar EDM del siguiente experimento no responde al deseo de mejorar la media, sino a reconocer una limitación intrínseca del dataset para ese subtipo bajo este protocolo.

3.5 EXPERIMENTO 3: CNN CON 5 CLASES, SIN EDM

3.5.1. Motivación

Una vez establecido que EDM no es evaluable bajo LOBO con los rodamientos disponibles, se construye un conjunto de evaluación que incluya únicamente los subtipos con soporte suficiente para la generalización inter-rodamiento. Esta decisión no es opcional: evaluar EDM bajo LOBO con un único rodamiento por clase produce resultados que no miden lo que se pretende medir.

3.5.2. Configuración

Cinco clases: Sano, IR (daño interno unificado), OR-Grabado, OR-Desgaste, OR-Taladro. Se evalúan 5 folds: K003 (Sano), KI01 (IR), KA05 (OR-Grabado), KA04 (OR-Desgaste), KA07 (OR-Taladro). Top-80 por F-score.

3.5.3. Resultados




Figura 4: Exactitud LOBO por rodamiento — CNN Top-80 con 5 clases, sin EDM. Media: 65.6 %.

La eliminación de EDM permite que la media suba a 65.6 %, un resultado esperado dado que se eliminó la clase más problemática. Sin embargo, KA05 (OR-Grabado) obtiene únicamente 19.7 %, apenas por debajo del nivel de azar (20 %), replicando el mismo problema estructural: KA05 es el *único* rodamiento OR-Grabado en el dataset, por lo que el modelo nunca ha visto ese subtipo durante el entrenamiento. Este resultado confirma el patrón observado desde el Experimento 1: bajo LOBO, los subtipos con un único rodamiento son inherentemente no evaluables

con este dataset.

3.6 EXPERIMENTO 4: MAPA AUTO-ORGANIZATIVO (SOM) COMO HERRAMIENTA DE VISUALIZACIÓN

3.6.1. Motivación

Los tres experimentos anteriores muestran que la exactitud LOBO está limitada por dos factores distintos: (1) la variabilidad inter-rodamiento que dificulta la generalización, y (2) el problema estructural de las clases con un único rodamiento. Para abordar el factor (1), se necesita comprender mejor la estructura del espacio de características. Se introduce un SOM como herramienta de análisis exploratorio: no para obtener un resultado de clasificación, sino para visualizar si las clases ocupan regiones topológicas diferenciadas en el espacio de características.

3.6.2. Configuración

Se entrena un SOM de 50×50 neuronas durante 500,000 iteraciones sobre las Top-80 características normalizadas. Esta etapa no está restringida por LOBO (usa todos los datos disponibles), lo cual es una limitación que se discute explícitamente en la Sección 3.10. Cada neurona se etiqueta con la clase mayoritaria de sus muestras activantes (*pureza de nodo*).

3.6.3. Resultados




Figura 5: Hit map del SOM 50×50 coloreado por clase dominante de cada neurona. Exactitud de asignación: 67.9%; Macro-F1: 0.662.




Figura 6: Mapas de densidad por clase sobre el SOM 25×25 . Cada panel muestra la concentración de activaciones de una clase en el espacio topológico.

El hit map muestra que el SOM organiza el espacio de forma coherente con las clases: Sano ocupa regiones diferenciadas, IR y OR-Desgaste presentan cierta separación, y EDM (violeta) aparece como manchas aisladas. Los mapas de densidad confirman que ninguna clase ocupa una región estrictamente exclusiva, lo que es consistente con los errores de clasificación observados en los experimentos anteriores.

La utilidad principal de este experimento fue identificar qué características generan la mayor pureza topológica, motivando el criterio de selección del Experimento 5.

3.7 EXPERIMENTO 5: SELECCIÓN DE CARACTERÍSTICAS POR PUREZA SOM

3.7.1. Motivación

El análisis de los experimentos anteriores mostró que las características con mayor F-score supervisado (dominadas por la vibración) producen un espacio que codifica la identidad del rodamiento tanto como la condición de falla, como lo evidencian los resultados bajo LOBO. Esto motivó buscar un criterio de selección alternativo que favorezca características estables entre rodamientos en lugar de características simplemente discriminantes en el conjunto de entrenamiento.

El F-score supervisado (ANOVA) puede favorecer features que capturan diferencias entre clases *dentro* del mismo rodamiento, pero que no generalizan a rodamientos nuevos. La **pureza SOM** ofrece una perspectiva diferente: una característica tiene alta pureza si las neuronas del SOM activadas por muestras de distintas clases son topológicamente separadas, independientemente de qué rodamiento provienen.

3.7.2. Método

Para cada característica f_i , se entrena un SOM univariante y se calcula la pureza media de todos sus nodos. Se ordenan las 272 características por pureza descendente y se seleccionan las Top-30.

3.7.3. Resultados




Figura 7: Ranking de las 30 características con mayor pureza SOM media. Las características de corriente (C2, C1) con descriptores de cola (*tail ratio*) y energía diferencial lideran el ranking, seguidas de características espectrales de vibración.

Las características de mayor pureza son C2_tail_ratio (0.627), C1_tail_ratio (0.590) y C2_diff_energy (0.546). Esto contrasta con el ranking por F-score, donde las características de vibración dominaban ampliamente. La selección por pureza SOM favorece descriptores de las señales de corriente, lo cual es coherente con la hipótesis de que la información eléctrica puede ser más estable entre rodamientos que la mecánica.

3.8 EXPERIMENTO 6 (FINAL): CNN CON TOP-30 POR PUREZA SOM

3.8.1. Motivación

Este experimento cierra el ciclo iterativo: se aplica la selección de características motivada por el análisis SOM a un clasificador CNN bajo evaluación LOBO estricta. La hipótesis es que

las 30 características con mayor pureza topológica generalizarán mejor a rodamientos nuevos que las 80 más discriminantes por criterio supervisado.

3.8.2. Configuración

Se mantiene la taxonomía de 5 clases del Experimento 3 (Sano, OR-Grabado, OR-Taladro, OR-Desgaste, IR), dado que es la configuración con mayor soporte identificada en los experimentos anteriores. Los folds LOBO emplean rodamientos distintos a los de los experimentos previos para evaluar rodamientos adicionales del dataset: K003 (Sano), KA06 (OR-Grabado), KA09 (OR-Taladro), KA22 (OR-Desgaste), KI07 (IR). La CNN recibe un vector de 30 características (Top-30 SOM-Pureza).

3.8.3. Resultados




Figura 8: Exactitud LOBO por rodamiento — CNN Top-30 SOM-Pureza. Media: **74.3 %**. Mejor resultado del Entregable 2.




Figura 9: Matriz de confusión LOBO — CNN Top-30 SOM-Pureza (5 folds). Sano alcanza 100 % de exactitud; IR logra 78.5 %; OR-Grabado permanece como la clase más difícil (36.9 %).

Los resultados por clase son: Sano 100 %, IR 78.5 %, OR-Desgaste 88.8 %, OR-Taladro 67.1 %, OR-Grabado 36.9 %. La exactitud media de **74.3 %** supera en 8.7 puntos porcentuales al mejor resultado previo con Top-80 por F-score (65.6 %), validando la hipótesis de que la pureza SOM selecciona características más robustas a la variabilidad inter-rodamiento.

OR-Grabado (KA06) sigue siendo la clase más difícil, confundida principalmente con OR-Taladro (3225 ventanas). Esto es coherente con la proximidad mecánica entre estos dos mecanismos y con el hecho de que OR-Grabado sigue teniendo escaso soporte en el dataset.

3.9 ANÁLISIS COMPARATIVO

La Tabla 4 resume la progresión de resultados a lo largo de los experimentos del Entregable 2.

Cuadro 4: Progresión iterativa de experimentos bajo protocolo LOBO.

Exp.	Clases	Selección	Acc. media	Motivo del cambio
E1	7 subtipos	Top-50 F-score	35.5 %	Punto de partida
E2	5 (EDM unificado)	Top-80 F-score	60.4 %	Confusión EDM en E1
E3	5 (sin EDM)	Top-80 F-score	65.6 %	EDM inviable en E2 (0 %)
E4	— (visualización)	—	67.9 %*	Diagnóstico del espacio
E6	5 (sin EDM)	Top-30 SOM	74.3 %	Hipótesis SOM-pureza

*Exactitud de asignación SOM sin restricción LOBO; no comparable directamente con los demás.

La tabla refleja que cada cambio de configuración responde a un hallazgo empírico concreto, no a una búsqueda de la configuración que maximiza la métrica. La reducción de 7 a 5 clases y

la eliminación de EDM son consecuencias de restricciones estructurales del dataset; la selección por pureza SOM es una hipótesis experimental motivada por el análisis exploratorio.

3.10 DISCUSIÓN

3.10.1. El problema de la identidad del rodamiento

Los experimentos confirman la observación fundamental de Lessmeier et al.: bajo LOBO, las características espectrales globales codifican en mayor medida la *identidad del rodamiento* que la *condición de falla*. Esto se manifiesta de dos formas:

- La confusión EDM entre IR y OR (Experimento 1): la firma del mecanismo de inducción supera la información de localización.
- La variabilidad inter-rodamiento dentro de la misma clase: incluso con soporte suficiente en entrenamiento, rodamientos nuevos del mismo subtipo presentan características significativamente diferentes.

3.10.2. Ventaja de la selección no supervisada

El ranking por pureza SOM favorece descriptores de las señales de corriente (`tail_ratio`, `diff_energy`), que el F-score supervisado prácticamente ignoraba en favor de las características de vibración. Esto sugiere que las señales eléctricas, aunque de menor amplitud, pueden ser más estables frente a la variabilidad inter-rodamiento que la señal mecánica, que captura características resonantes específicas del montaje.

3.10.3. Limitaciones

- **Pureza SOM calculada sin restricción LOBO:** el SOM se entrenó con todos los datos disponibles, introduciendo cierta filtración de información de test en la selección de características. Una evaluación más rigurosa calcularía la pureza solo con datos de entrenamiento de cada fold.
- **Clases con un único rodamiento:** OR-Grabado (KA06), IR-EDM (KI01) y OR-EDM (KA01/KA02) siguen siendo problemáticos porque el dataset no proporciona suficiente diversidad inter-rodamiento para esos subtipos. Este es un límite del dataset, no del método.
- **Variación entre folds de distintos experimentos:** dado que los experimentos usan distintos rodamientos de test, las métricas no son directamente comparables entre todos los experimentos. La comparación entre E3 y E6 (que mantienen la misma taxonomía de clases) es la más rigurosa de la tabla.

CONCLUSIONES

Este entregable demuestra que la ingeniería de características ofrece ventajas interpretativas sobre el enfoque de señal cruda del Entregable 1, y que el diseño experimental iterativo guiado por los propios resultados permite identificar las limitaciones del dataset y del espacio de características de forma sistemática. Los hallazgos principales son:

1. **EDM no es separable entre IR y OR bajo LOBO:** la firma espectral del mecanismo de descarga eléctrica domina sobre las frecuencias características de localización del daño. Esta es una restricción del dataset: ambos subtipos EDM están representados por un único rodamiento cada uno.
2. **La selección de características por pureza SOM supera al F-score supervisado:** 30 features seleccionadas de forma no supervisada producen 74.3 % de exactitud LOBO media frente al 65.6 % de 80 features supervisadas, con la misma taxonomía de clases.
3. **La detección de rodamiento sano es robusta:** en todos los experimentos, la clase Sano alcanza exactitudes superiores al 90 % bajo LOBO, indicando que la separación sano/dañado es generalizable.
4. **La progresión experimental fue guiada por hallazgos, no por optimización de métricas:** cada cambio en la configuración de clases responde a una limitación observable del dataset o del clasificador, documentada en la matriz de confusión o en el análisis exploratorio.

REFERENCIAS

- [Koh90] Teuvo KOHONEN. “The Self-Organizing Map”. En: *Proceedings of the IEEE* 78.9 (1990), págs. 1464-1480.
- [LeC+98] Yann LECUN et al. “Gradient-Based Learning Applied to Document Recognition”. En: *Proceedings of the IEEE* 86.11 (1998), págs. 2278-2324.
- [Les+16] Christian LESSMEIER et al. “Condition Monitoring of Bearing Damage in Electro-mechanical Drive Systems by Using Motor Current Signals of Electric Motors: A Benchmark Data Set for Data-Driven Classification”. En: *European Conference of the Prognostics and Health Management Society*. Bilbao, Spain, 2016.