

Inteligencia Computacional

PROYECTO FINAL — PROPUESTA INICIAL

Johan Sebastián Cáceres Rodríguez
20212005111

Joel Eduardo Reyes Barrios
20212005011

March 25, 2026



**UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS**
Acreditación Institucional de Alta Calidad

CONTENTS

1	Título del Proyecto	4
2	Resumen	4
3	Introducción	4
4	Estado del Arte	5
5	Planteamiento del Problema	6
6	Justificación	6
6.1	Viabilidad económica del monitoreo por corriente	6
6.2	Brecha entre laboratorio y aplicación real	6
6.3	Valor del análisis comparativo	7
7	Descripción del Dataset	7
8	Análisis Preliminar Esperado del Dataset	7
8.1	Esquemas de etiquetado	8
8.2	Desbalance de clases	8
8.3	Preprocesamiento necesario	8
8.4	Riesgo de fuga de información	8
9	Objetivos	8
9.1	Objetivo General	9
9.2	Objetivos Específicos	9
10	Hipótesis de Trabajo	9
11	Metodología Propuesta	10
11.1	Exploración y análisis de datos	10
11.2	Segmentación y normalización	10
11.3	Representaciones de la señal	10
11.4	Estrategia de partición	11

12 Métricas de Evaluación	11
13 Resultados Esperados e Hipótesis de Desempeño	11
14 Limitaciones y Riesgos	12
15 Entregables	12
16 Conclusiones Preliminares	14
17 Referencias	14

1

TÍTULO DEL PROYECTO

Análisis de generalización de redes neuronales para el diagnóstico de fallas en rodamientos externos mediante señales de corriente del motor: impacto de la representación de la señal y la granularidad de etiquetas.

2

RESUMEN

Este documento presenta la propuesta inicial de un proyecto cuyo objetivo central es evaluar la robustez y capacidad de generalización de distintas arquitecturas de redes neuronales para clasificar estados de salud de rodamientos utilizando exclusivamente señales de corriente del motor (Motor Current Signature, MCS). El estudio se apoya en el conjunto de datos del Bearing Data Center de la Universidad de Paderborn, y aborda dos preguntas metodológicas fundamentales: ¿en qué medida el desempeño del modelo depende de la representación empleada para la señal de entrada?; y ¿conviene definir etiquetas gruesas por ubicación de la falla (IR / OR) o etiquetas finas por mecanismo y severidad del daño? El proyecto no busca reportar la mayor exactitud posible sobre un conjunto de prueba, sino diseñar un protocolo experimental riguroso que permita medir la generalización real del modelo frente a rodamientos no vistos durante el entrenamiento, abordando de forma explícita los riesgos de fuga de información, desbalance de clases y sobreajuste.

3

INTRODUCCIÓN

El diagnóstico de fallas en rodamientos constituye uno de los problemas más estudiados en el mantenimiento predictivo de maquinaria rotativa. La mayor parte de la literatura propone soluciones basadas en señales de vibración capturadas con acelerómetros dedicados; sin embargo, la instalación de este tipo de sensores implica costos de adquisición, calibración y cableado que limitan su adopción industrial generalizada. Una alternativa de menor costo consiste en extraer información diagnóstica directamente de las señales de corriente del motor eléctrico, cuya medición es posible a través de los inversores de frecuencia ya instalados en la planta.

Desde el punto de vista del procesamiento de señales, la detección de fallas a partir de MCS representa un desafío significativo: la firma del daño mecánico llega al estator de forma indirecta,

modulada por el torque y atenuada por la cadena cinemática, lo que produce perturbaciones de muy baja amplitud sobre una portadora dominante a la frecuencia de red (50 o 60 Hz). A esto se suma la presencia de armónicos de conmutación del inversor y ruido de proceso, lo que hace necesario un preprocesamiento cuidadoso antes de cualquier etapa de aprendizaje automático.

En este contexto, el presente proyecto propone un análisis comparativo estructurado entre diferentes representaciones de la señal (señal cruda segmentada), características estadísticas y espectrales, e imágenes tiempo-frecuencia y entre distintos esquemas de etiquetado, desde la clasificación binaria hasta la separación por mecanismo y severidad de daño. El valor del trabajo reside en el rigor del diseño experimental y en la capacidad de responder si las conclusiones obtenidas en condiciones de laboratorio son transferibles a escenarios industriales reales.

4

ESTADO DEL ARTE

El diagnóstico de fallas en rodamientos ha evolucionado desde métodos basados exclusivamente en vibraciones hacia enfoques que explotan señales eléctricas, motivados por la reducción de costos de instrumentación. Los trabajos pioneros en análisis de firma de corriente del motor (*Motor Current Signature Analysis*, MCSA) demostraron que las frecuencias características de falla (BPFO, BPFI) se manifiestan como modulaciones de amplitud sobre la corriente del estator, aunque con relación señal-ruido considerablemente inferior a la obtenida con acelerómetros [ref6].

Con la popularización del aprendizaje profundo, varios autores propusieron arquitecturas convolucionales unidimensionales (1D-CNN) que operan directamente sobre la señal cruda de corriente o vibración, eliminando la necesidad de ingeniería de características manual [ref3]. Estas arquitecturas mostraron resultados competitivos bajo particiones aleatorias de ventanas; sin embargo, trabajos más recientes advierten que dicha evaluación introduce fuga de información cuando múltiples ventanas del mismo rodamiento aparecen simultáneamente en entrenamiento y prueba [ref7].

El dataset de Paderborn ha sido adoptado como banco de pruebas común precisamente porque incluye rodamientos con daños artificiales y reales, permitiendo estudiar la transferibilidad del modelo entre condiciones de laboratorio y operación acelerada [ref1]. La comparación entre representaciones de señal (cruda, características estadístico-espectrales, imágenes tiempo-frecuencia) y su interacción con el esquema de partición constituye la brecha metodológica que este proyecto busca cubrir.

PLANTEAMIENTO DEL PROBLEMA

Dos preguntas centrales articulan el proyecto:

1. **Generalización del modelo:** ¿Qué tan bien clasifica una red neuronal las fallas de rodamientos a partir de señales MCS cuando se evalúa sobre rodamientos *no vistos* durante el entrenamiento, y cómo varía ese desempeño según la representación elegida para la señal y la estrategia de partición del conjunto de datos?
2. **Granularidad de etiquetas:** ¿Conviene agrupar las fallas por ubicación (IR/OR) o separarlas por mecanismo de daño (EDM, grabado eléctrico, taladrado) y nivel de severidad? ¿La mayor granularidad aporta interpretabilidad o introduce fragmentación excesiva que desestabiliza el entrenamiento?

Estas preguntas son relevantes porque la literatura reporta una discrepancia importante entre las métricas obtenidas en validación cruzada convencional donde se mezclan ventanas del mismo rodamiento en entrenamiento y prueba y las obtenidas en validación cruzada por rodamiento (*Leave-One-Bearing-Out*, *LOBO*), que exige que el modelo generalice a una instancia física completamente nueva. Esta distinción metodológica define si el modelo aprendió la firma física de la falla o simplemente memorizó características particulares de ese motor específico.

JUSTIFICACIÓN

6.1 VIABILIDAD ECONÓMICA DEL MONITOREO POR CORRIENTE

El monitoreo basado en acelerómetros requiere sensores externos, cableado especializado y equipos de adquisición de datos adicionales. El uso de señales de corriente medidas directamente a través del variador de frecuencia elimina la necesidad de sensores adicionales, lo que lo convierte en una solución de bajo costo para motores de pequeña y mediana potencia en entornos industriales. Esta característica justifica el interés académico e industrial en mejorar la calidad de los modelos basados exclusivamente en MCS.

6.2 BRECHA ENTRE LABORATORIO Y APLICACIÓN REAL

Estudios previos señalan que el entrenamiento con daños artificiales (generados por mecanizado o descarga eléctrica controlada) y la evaluación con daños reales (originados por fatiga o desgaste progresivo) produce caídas drásticas en la exactitud del clasificador. Este proyecto ataca

directamente esa brecha, diseñando el esquema experimental de forma que la evaluación final se realice sobre condiciones lo más cercanas posible a la operación real.

6.3 VALOR DEL ANÁLISIS COMPARATIVO

Más allá de reportar un resultado numérico, el proyecto busca generar conocimiento transferible: establecer qué representación y qué nivel de granularidad producen modelos más robustos, de qué forma las decisiones de preprocesamiento afectan la generalización, y cuál es el costo de aumentar la resolución del esquema de etiquetas en términos de desbalance y estabilidad del entrenamiento.

7

DESCRIPCIÓN DEL DATASET

Se utilizará el conjunto de datos del *Bearing Data Center* de la Universidad de Paderborn, ampliamente referenciado en la literatura de diagnóstico de fallas. El dataset incluye mediciones sincrónicas de corriente del motor y vibración del eje, adquiridas a una frecuencia de muestreo de 64 kHz bajo diferentes condiciones de carga y velocidad angular.

Los rodamientos del conjunto se clasifican en tres grandes grupos:

- **Rodamientos sanos (H):** Sin intervención previa; sirven como referencia del comportamiento nominal.
- **Rodamientos con daño artificial:** Fallas introducidas de forma controlada por tres mecanismos distintos: descarga por electroerosión (EDM), grabado eléctrico (*electric engraver*) y taladrado (*drilling*). Cada mecanismo genera una firma de desgaste geométrica diferente.
- **Rodamientos con daño real:** Fallas generadas por fatiga acelerada en banco de pruebas. Este subconjunto tiene una distribución intrínsecamente desbalanceada, con predominancia de daños por fatiga de contacto (*pitting*).

Para cada rodamiento dañado, el nivel de severidad está catalogado en cinco grados (1 a 5) tanto para el aro interno (IR) como para el externo (OR), lo que habilita el diseño de esquemas de etiquetado con distinto nivel de detalle, desde 3 hasta más de 12 clases.

8

ANÁLISIS PRELIMINAR ESPERADO DEL DATASET

8.1 ESQUEMAS DE ETIQUETADO

Se contemplarán al menos tres niveles de granularidad en la definición de clases, resumidos en la Tabla 1.

Table 1: Esquemas de etiquetado propuestos según nivel de granularidad.

Nivel	Clases	Descripción
Grueso	H / IR / OR	Clasificación por ubicación de la falla. Máxima agregación; menor riesgo de desbalance.
Fino	H / OR_EDM / OR_eng / OR_drill / IR_EDM / IR_eng / IR_drill / ...	Separación por mecanismo de daño y nivel de severidad. Mayor interpretabilidad física pero riesgo elevado de desbalance.

8.2 DESBALANCE DE CLASES

A medida que aumenta la granularidad, el número de muestras por clase disminuye de forma desigual. Los daños reales representan un porcentaje minoritario del total de experimentos y, dentro de ellos, los niveles de severidad bajos (grado 1) cuentan con pocas repeticiones. Se anticipa que el esquema fino presentará ratios de desbalance superiores a 10:1 en algunas categorías, lo que requiere estrategias específicas de evaluación y, potencialmente, de remuestreo.

8.3 PREPROCESAMIENTO NECESARIO

La señal cruda de 64 kHz deberá segmentarse en ventanas de longitud fija antes de su ingesta al modelo. La elección del tamaño de ventana y el solapamiento entre ventanas influye directamente sobre la cantidad de muestras generadas y sobre el riesgo de contaminación entre conjuntos. Se realizará normalización por ventana o por rodamiento según el esquema de partición adoptado.

8.4 RIESGO DE FUGA DE INFORMACIÓN

Una partición aleatoria de ventanas temporales generadas a partir del mismo rodamiento distribuye fragmentos del mismo experimento físico tanto en el conjunto de entrenamiento como en el de prueba. Esto produce estimaciones de generalización artificialmente optimistas. Para evitar esta fuga se adoptará una separación estricta por rodamiento antes de la segmentación en ventanas.

9.1 OBJETIVO GENERAL

Evaluar la capacidad de generalización de modelos de redes neuronales para el diagnóstico de fallas en rodamientos a partir de señales de corriente del motor, analizando el impacto de la representación de la señal y la granularidad del esquema de etiquetas sobre el desempeño y la robustez del clasificador.

9.2 OBJETIVOS ESPECÍFICOS

1. Realizar un análisis exploratorio detallado del dataset de Paderborn, caracterizando la distribución de clases bajo cada esquema de etiquetado y cuantificando el desbalance esperado.
2. Ampliar la base de datos mediante técnicas de interpolación sintética, generando un conjunto de entrenamiento significativamente mayor que preserve las características estadísticas de las señales originales y permita balancear las clases de falla identificadas.
3. Implementar al menos dos representaciones de la señal: señal cruda segmentada y vector de características estadísticas y espectrales en el dominio del tiempo-frecuencia.
4. Diseñar una estrategia de partición por rodamiento (*Leave-One-Bearing-Out*) que garantice la separación estricta de instancias físicas entre los conjuntos de entrenamiento y evaluación.
5. Entrenar y evaluar arquitecturas neuronales adecuadas a cada representación: redes densas (MLP) para vectores de características y redes convolucionales 1D (1D-CNN) para señal cruda bajo cada esquema de etiquetado definido.
6. Comparar el desempeño de los modelos mediante métricas sensibles al desbalance de clases (*Macro-F1 Score*, precisión y exhaustividad), e interpretar los errores del clasificador a través de matrices de confusión.

10

HIPÓTESIS DE TRABAJO

1. Una partición por rodamiento producirá métricas de generalización significativamente inferiores a las obtenidas con una partición aleatoria de ventanas, poniendo en evidencia el sobreajuste latente que las particiones convencionales encubren.
2. Las representaciones basadas en características extraídas del dominio frecuencial (kurtosis espectral, energía de bandas) generalizarán mejor que la señal cruda en escenarios de pocas muestras por clase, dado que incorporan conocimiento del dominio físico que reduce

la dimensión efectiva del problema.

3. El esquema de etiquetado fino aumentará el *Macro-F1 Score* en la detección de fallas de baja severidad, pero reducirá la estabilidad del entrenamiento y la exactitud global, reflejando el compromiso inherente entre interpretabilidad y robustez estadística.

11

METODOLOGÍA PROPUESTA

11.1 EXPLORACIÓN Y ANÁLISIS DE DATOS

La primera etapa consiste en cargar el conjunto de datos completo e identificar la distribución de experimentos por tipo de rodamiento, mecanismo de daño, nivel de severidad y condición de carga. Se construirán histogramas de duración de señal por clase y se cuantificará el desbalance antes de cualquier segmentación.

11.2 SEGMENTACIÓN Y NORMALIZACIÓN

La señal continua de corriente se dividirá en ventanas de longitud fija. La longitud de ventana se escogerá de forma que contenga al menos dos periodos completos de la frecuencia de falla más baja esperada. El solapamiento entre ventanas consecutivas se ajustará para equilibrar el número de muestras entre clases sin introducir contaminación entre conjuntos. La normalización (media cero, desviación unitaria) se calculará exclusivamente sobre el subconjunto de entrenamiento y se aplicará al resto.

11.3 REPRESENTACIONES DE LA SEÑAL

Se considerarán dos estrategias de representación:

Representación A — Señal cruda (Raw): cada ventana temporal se ingresa directamente como vector de entrada a una 1D-CNN, que aprende sus propios filtros de extracción sin sesgo de ingeniería.

Representación B — Características extraídas (Feature-Based): de cada ventana se calculan estadísticos en el dominio del tiempo (media, RMS, kurtosis, factor de cresta) y en el dominio espectral (energía en bandas de frecuencia correspondientes a BPFO y BPFI, densidad espectral de potencia). El vector resultante alimenta un perceptrón multicapa (MLP).

11.4 ESTRATEGIA DE PARTICIÓN

Se adoptará la validación cruzada por rodamiento (*Leave-One-Bearing-Out*): en cada fold, todos los experimentos asociados a un rodamiento específico se reservan íntegramente para prueba, y el modelo se entrena con el resto. Esta estrategia garantiza que el modelo deba generalizar a una instancia física completamente nueva, midiendo robustez real en lugar de memorización.

12

MÉTRICAS DE EVALUACIÓN

Dado el desbalance esperado, la exactitud (*accuracy*) no se empleará como métrica principal. Se priorizarán las siguientes métricas:

- **Macro-F1 Score:** promedio no ponderado del F_1 de cada clase, que penaliza por igual el bajo desempeño en cualquier categoría independiente de su frecuencia:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (12.1)$$

- **Precisión y Exhaustividad (*Recall*) por clase:** para identificar si el modelo presenta sesgos hacia las clases mayoritarias.
- **Exactitud global:** reportada como referencia secundaria y para contraste con trabajos previos de la literatura.
- **Matriz de confusión:** se construirá una matriz de confusión para cada experimento, clasificando los errores en dos categorías: errores entre severidades de un mismo componente (aceptables desde el punto de vista operacional) y errores entre componentes distintos (críticos, pues implican una acción de mantenimiento incorrecta).

13

RESULTADOS ESPERADOS E HIPÓTESIS DE DESEMPEÑO

Sin anticipar resultados experimentales, se formulan las siguientes expectativas a partir de la literatura revisada:

- Los modelos evaluados con partición LOBO presentarán métricas significativamente inferiores ($\Delta F_1 > 0.1$) respecto a los mismos modelos evaluados con partición aleatoria de ventanas, confirmando el efecto de la fuga de información.
- La representación por características superará a la señal cruda en los esquemas de etiquetado fino, donde el número de muestras por clase es reducido, debido a que el conocimiento de dominio incorporado en los vectores de características compensa la escasez de datos.

- El esquema intermedio producirá la mejor relación entre interpretabilidad y estabilidad del entrenamiento; el esquema fino exhibirá alta varianza entre folds de la validación cruzada, reflejando la sensibilidad del modelo al número de muestras disponibles.

14

LIMITACIONES Y RIESGOS

- **Escasez de rodamientos con daño real:** el número de instancias físicas con daño por fatiga es reducido, lo que puede producir varianza elevada en la estimación LOBO y dificultar la generalización a ese subconjunto.
- **Condiciones de operación fijas:** el dataset fue adquirido bajo condiciones de carga y velocidad controladas. Los resultados pueden no ser directamente transferibles a máquinas con velocidad variable o ciclos de carga dinámicos.
- **Selección del tamaño de ventana:** la elección de este parámetro afecta simultáneamente la resolución frecuencial, la cantidad de muestras y el nivel de solapamiento entre ventanas. Una elección inadecuada puede introducir sesgo en la comparación entre representaciones.
- **Capacidad computacional:** el entrenamiento de redes convolucionales sobre señales de 64kHz puede ser costoso en términos de memoria y tiempo. Se evaluará la posibilidad de reducir la frecuencia de muestreo de forma controlada sin perder las componentes de interés.

15

ENTREGABLES

El proyecto se estructura en dos entregas formales. Cada entrega tiene un alcance delimitado y produce artefactos concretos: código reproducible en Google Colab, reporte escrito de resultados y análisis crítico.

ENTREGA 1 — EDA Y CLASIFICACIÓN CON SEÑAL CRUDA

Esta entrega replica y valida el enfoque del trabajo de referencia de Paderborn, sentando la línea base experimental del proyecto.

- **Análisis exploratorio (EDA):** carga del dataset completo, verificación de integridad de archivos, distribución de experimentos por tipo de rodamiento (H / IR / OR), mecanismo

de daño y nivel de severidad. Visualización de señales representativas de corriente por clase y cuantificación del desbalance bajo el esquema de etiquetado grueso (3 clases).

- **Preprocesamiento y ventaneo:** segmentación de la señal continua en ventanas de longitud fija, definición del solapamiento y separación estricta por rodamiento (protocolo LOBO) para evitar fuga de información entre conjuntos de entrenamiento y prueba.
- **Modelo base — 1D-CNN:** entrenamiento de una red convolucional unidimensional sobre la señal cruda segmentada bajo el esquema de etiquetado grueso (H / IR / OR). Se reportarán Macro-F1, precisión y exhaustividad por clase, y matriz de confusión, evaluados exclusivamente con la partición LOBO.

ENTREGA 2 — GRANULARIDAD, CARACTERÍSTICAS Y ANÁLISIS COMPARATIVO

Esta entrega extiende los resultados de la Entrega 1 hacia las dos preguntas centrales del proyecto: impacto de la granularidad de etiquetas e impacto de la representación de la señal.

- **Esquemas de etiquetado fino:** Esquemas de 5 y ≥ 10 clases definidos en la Tabla 1, con análisis del desbalance y ajuste de pesos de clase.
- **Vector de características — MLP:** extracción de estadísticos en el dominio del tiempo (RMS, kurtosis, factor de cresta) y en el dominio espectral (energía en bandas BPFO/BPFI, densidad espectral de potencia) para cada ventana; entrenamiento de un perceptrón multicapa (MLP) bajo los mismos esquemas de etiquetado y partición LOBO.
- **Análisis comparativo — 1D-CNN vs. MLP:** comparación sistemática de los seis experimentos resumidos en la Tabla 2 según representación, arquitectura y granularidad de etiquetas, utilizando Macro-F1 como métrica principal. Se interpretarán las matrices de confusión diferenciando errores críticos (entre componentes) de errores aceptables (entre severidades del mismo componente).

Table 2: Matriz de experimentos del proyecto.

Exp.	Representación	Esquema de etiquetas	Arquitectura
E1	Señal cruda	Grueso (3 clases)	1D-CNN
E2	Características	Grueso (3 clases)	MLP
E3	Características	Fino (≥ 10 clases)	MLP
E4	Señal cruda	Fino (≥ 10 clases)	1D-CNN

CONCLUSIONES PRELIMINARES

Este documento establece los fundamentos metodológicos de un proyecto que va más allá del entrenamiento convencional de una red neuronal. El diseño experimental propuesto aborda de forma explícita los tres puntos de falla más comunes en la literatura de diagnóstico de fallas: la fuga de información por partición inadecuada, el sesgo introducido por el desbalance de clases y la sobre estimación del desempeño al no separar instancias físicas entre conjuntos.

La comparación sistemática entre representaciones y niveles de granularidad generará conclusiones transferibles sobre qué decisiones metodológicas impactan más en la capacidad real de generalización de los modelos, aportando valor tanto al campo académico como a la práctica industrial del monitoreo de condición de bajo costo.

ALCANCE INICIAL DEL PROYECTO

Como punto de partida, el trabajo inmediato consistirá en la exploración detallada del dataset de Paderborn: verificar la integridad de los archivos, construir el mapa de experimentos disponibles por tipo y severidad de daño, cuantificar el desbalance bajo cada esquema de etiquetado y visualizar señales representativas de cada clase. A partir de ese análisis exploratorio se definirá el esquema de clases definitivo, la longitud de ventana y el protocolo de partición, antes de proceder al diseño e implementación de las arquitecturas neuronales.

REFERENCIAS

1. Lessmeier, C. *et al.* (2016). Condition monitoring of bearing damage in electromechanical drive systems by using motor current signals of electric motors: A benchmark data set for data-driven classification. *PHM Society European Conference*, Vol. 3.
2. Nectoux, P. *et al.* (2012). PRONOSTIA: An experimental platform for bearings accelerated degradation tests. *IEEE International Conference on Prognostics and Health Management*.
3. Ince, T. *et al.* (2016). Real-time motor fault detection by 1-D convolutional neural networks. *IEEE Transactions on Industrial Electronics*, 63(11), 7067–7075.
4. Zhang, W., Peng, G., Li, C. (2017). Bearing fault diagnosis using convolutional neural networks with 2D representations of vibration signals as input. *Journal of Physics:*

- Conference Series*, 364, 012051.
5. Bearing Data Center, Universidad de Paderborn. <https://mb.uni-paderborn.de/kat/forschung/kat-datacenter/bearing-datacenter/>
 6. Henao, H. *et al.* (2014). Trends in Fault Diagnosis for Electrical Machines: A Review of Diagnostic Techniques. *IEEE Industrial Electronics Magazine*, 8(2), 31–42.
 7. Hoang, D.T., Kang, H.J. (2019). A survey on Deep Learning based bearing fault diagnosis. *Neurocomputing*, 335, 327–335.
 8. Verstraete, D. *et al.* (2017). Deep learning enabled fault diagnosis using time-frequency image analysis of rolling element bearings. *Shock and Vibration*, 2017, 5067651.